

Д30: критерии оценки веб-поисковиков

Георгий Мамарин

1. Коротко

Смущенный форматом сдачи и непривычностью работы в такой структуре, в этом отчете я предлагаю набор критериев для оценки веб-поисковиков и показываю, как по ним можно сравнить Google, Yandex, ChatGPT и Gemini. Основная идея состоит в том, что для классического поиска и для LLM-инструментов нужны частично различающиеся критерии, а итоговая оценка должна учитывать тип запроса и исходную потребность пользователя.

2. Постановка задачи

Если оценивать поисковик только через общую «релевантность», мы потеряем различия между задачами. Навигационный запрос вроде вшэ факультет компьютерных наук требует быстро найти один конкретный сайт, а запрос на сравнение или объяснение требует скорее хорошего покрытия темы и удобного ответа. На мой взгляд, оценка поисковика должна быть завязана на тип информационной потребности пользователя.

Традиционный подход к поиску качественно изменился из-за глубины проникновения LLM-инструментов. В классическом поиске пользователь чаще получает список ссылок, из которых он делает вывод самостоятельно, прокликая их одну за другой. А в ChatGPT или Gemini он часто получает уже готовый ответ, который может проверить через подобранные источники, если LLM подкрепит ими свою генерацию. Из-за этого сравнивать все системы одной и той же метрикой становится мало разумным: для части задач важнее ранжирование документов, а для другой — качество синтезированного ответа.

3. Критерии оценки

Мне кажется, критерии удобнее описывать не как длинный список, а как несколько более общих измерений.

Первое измерение — это **качество поиска**. Для традиционных поисковиков его разумно измерять стандартными метриками:

- Success@1 или MRR для навигационных запросов;
- NDCG@10 для информационных запросов;

- Recall@k или покрытием аспектов для более исследовательских сценариев.

Они хорошо отражают ситуацию, когда система возвращает ранжированный список документов.

Второе измерение — **качество самого ответа**. Для LLM-инструментов одного качества ранжирования мало. Здесь нужно отдельно смотреть на:

- **корректность ответа**;
- **наличие опоры на источники**;
- **галлюцинации**, то есть случаи, когда система уверенно выдает неподтвержденные утверждения.

Иными словами, хороший ответ должен быть не только удобным, но и проверяемым.

Третье измерение — **стоимость достижения результата для пользователя**. Даже если система в конце концов приводит к верному ответу, важно, сколько шагов для этого нужно: придется ли переформулировать запрос, переходить по нескольким ссылкам или давать дополнительные вводные.

Четвертое измерение — **устойчивость к реальным запросам**. Здесь я бы выделил:

- **задержку** — слишком медленный ответ ухудшает пользовательский опыт;
- **устойчивость к нечетким и неоднозначным запросам**;
- **локальную и языковую адаптацию** — насколько система хорошо работает с русским языком, локальным контекстом и смешанными запросами.

Пятое измерение — **доверие к системе**. Сюда входят:

- видимость ссылок и источников;
- понятность происхождения ответа;
- отсутствие навязчивости;
- **приватность** — часть пользователей будет предпочитать менее навязчивую систему, соглашаясь на возможное падение качества.

Чтобы сделать итоговую оценку зависимой от сценария, предлагаю ввести три профиля задач:

- **навигационный веб-поиск** — важнее всего качество поиска, скорость и низкая стоимость достижения результата;

Профиль	Поиск	Ответ	Стоимость результата	Устойчивость	Доверие
Навигационный веб-поиск	40%	5%	25%	20%	10%
Исследовательский поиск	10%	35%	20%	15%	20%
Русскоязычный локальный поиск	25%	10%	15%	35%	15%

Таблица 1: Веса укрупненных измерений для разных профилей задач.

Критерий	Google	Yandex	ChatGPT	Gemini
Качество поиска	5.0	5.0	2.0	3.0
Качество ответа	2.5	2.0	4.5	4.0
Стоимость результата	4.0	4.0	5.0	4.0
Устойчивость	4.0	5.0	4.0	3.5
Доверие	2.0	2.0	2.0	2.0

Таблица 2: Базовые оценки по пяти укрупненным измерениям.

- исследовательский / сравнительный поиск — важнее качество синтеза, проверяемость и возможность быстро собрать ответ из нескольких источников;
- русскоязычный локальный поиск — важнее языковая адаптация, локальный контекст и устойчивость к реальным пользовательским формулировкам.

Для этих профилей можно использовать разные веса по укрупненным измерениям:

4. Набор сценариев

Чтобы сравнение не было слишком узким, я бы включил в набор запросов шесть сценариев: навигационный (всё факультет компьютерных наук), информационный (что такое BM25), исследовательский (сравнение BM25 и dense retrieval), неоднозначный (питон), локальный (кофейня рядом со мной) и мультиязычный (lemmatization для русского языка). Такой набор покрывает не только «поиск факта», но и реальные случаи, где пользователю нужны уточнение запроса, локальная информация или сравнение нескольких источников.

Этот набор также учитывает различия между пользователями. Более опытным пользователям важнее качество источников и полнота покрытия темы. Массовым пользователям важнее скорость ответа и понятность интерфейса. Пользователям, которые заботятся о приватности, важно, насколько навязчиво система собирает данные и показывает рекламу.

5. Краткое сравнение систем

Таблица 2 показывает упрощенное качественное сравнение по шкале от 1 до 5. Это не полноценный эксперимент, а скорее способ показать, как выбранные критерии разделяют сильные и слабые стороны разных систем.




Рис. 1: Слева веса профилей задач, справа итоговые баллы систем при этих весах.

Из такого сравнения видно две основные вещи. Во-первых, **традиционные поисковики остаются сильнее в поиске по вебу как таковому**. Google особенно хорош, когда нужно быстро найти каноническую страницу, свежие материалы или общемировые результаты. Яндекс особенно естественно выглядит в задачах с русскоязычными запросами, локальным контекстом и поиском по привычным российским сервисам.

Во-вторых, **LLM-системы сильнее там, где нужен синтез информации и снижение пользовательских усилий**. ChatGPT и Gemini удобнее для суммаризации, сравнения и последовательного уточнения вопроса. Но именно для них особенно важно проверять наличие источников: удобный и гладкий ответ без подтверждения не должен автоматически считаться хорошим результатом.

Если применить к этим оценкам веса из разных профилей задач, получится, что лидеры действительно меняются в зависимости от сценария: в навигационном и локальном русскоязычном профиле сильнее выглядят Google и Yandex, а в исследовательском профиле вперед выходят ChatGPT и Gemini.

6. Заключение

Таким образом, «лучший поисковик» нельзя определить одной общей метрикой. Корректнее оценивать системы по набору критериев, который зависит от сценария использования. Для классических поисковиков важнее релевантность, полнота, свежесть и задержка. Для LLM-инструментов к этому добавляются качество ответа, наличие источников и отсутствие галлюцинаций.

Практически это означает, что лучше подбирать не один универсальный сервис, а набор инструментов под россыпь задач.