

# Отчет по основной части ДЗ1

## 1. Постановка задачи

В основной части работы нужно проанализировать коллекцию WikIR<sub>en1k</sub>: посчитать базовые статистики, исследовать частотное распределение слов, проверить законы Ципфа и Хипса, проанализировать биграммы и сравнить несколько способов нормализации текста.

Для анализа использовался файл `documents.csv` из коллекции `wikIR1k`. В условии указано, что документы уже очищены, приведены к нижнему регистру и токенизированы, поэтому базовая единица анализа в отчете — готовый токен.

## 2. Базовые статистики коллекции

| Показатель                      | Значение   |
|---------------------------------|------------|
| Число документов                | 99 987     |
| Размер коллекции в токенах      | 19 963 076 |
| Средняя длина документа         | 199.6567   |
| Число уникальных слов           | 285 376    |
| Средняя длина слова             | 4.6934     |
| Средняя длина уникального слова | 7.5235     |



Эти числа показывают, что коллекция достаточно крупная для корпусного анализа: почти сто тысяч документов и около двадцати миллионов токенов. При этом словарь корпуса очень большой, что естественно для энциклопедического домена.

## 3. Частотный словарь слов и stopwords

### Топ-10 самых частотных слов


| Слово | Частота | Ранг | Stopword |
|-------|---------|------|----------|
| the   | 1557812 | 1    | Да       |
| of    | 881627  | 2    | Да       |
| and   | 567768  | 3    | Да       |
| in    | 515312  | 4    | Да       |
| a     | 389090  | 5    | Да       |
| to    | 343354  | 6    | Да       |
| was   | 308940  | 7    | Да       |
| is    | 267701  | 8    | Да       |
| as    | 191301  | 9    | Да       |
| were  | 142334  | 10   | Да       |

Stopwords дают 8 101 999 вхождений, то есть 40.58% всех токенов коллекции. Не все слова из top-30 являются стоп-словами: среди частотных содержательных токенов встречаются `census`, `population`, а также числовые токены 0 и 1.



По этим результатам видно, что классический stopwords list полезен, но не должен расширяться автоматически по сырым частотам корпуса: частотное слово может быть доменно значимым, а не служебным.

#### 4. Законы Ципфа и Хипса



На log-log графике зависимости rank-frequency наблюдается типичное почти линейное поведение: небольшое число слов имеет очень высокую частоту, а основная масса слов редка. Это соответствует закону Ципфа.





График роста словаря показывает сублинейный рост: по мере чтения новых токенов словарь продолжает расширяться, но скорость появления новых слов постепенно падает. Это соответствует закону Хипса.

## 5. Частотный словарь биграмм

В коллекции получилось 4 083 973 уникальных биграммы. Верхушка списка по сырой частоте сильно засорена служебными сочетаниями, поэтому для отбора полезных биграмм нужен отдельный критерий.

### Топ-10 биграмм по частоте

| Биграмма       | Частота |
|----------------|---------|
| of the         | 265328  |
| in the         | 147038  |
| to the         | 93293   |
| the population | 66719   |
| there were     | 57311   |
| at the         | 56370   |
| and the        | 47362   |
| it is          | 41907   |
| on the         | 37815   |
| united states  | 37437   |



### Биграммы, прошедшие формальный критерий отбора



В качестве рабочего критерия использовалась комбинация условий: frequency  $\geq 20$ , биграмма не должна состоять из двух stopwords одновременно, а мера ассоциации PMI должна быть не меньше 3.

| Биграмма           | Частота | PMI    | Оба stopwords |
|--------------------|---------|--------|---------------|
| united states      | 37437   | 8.776  | Нет           |
| according to       | 32694   | 5.8653 | Нет           |
| 2010 census        | 28839   | 7.311  | Нет           |
| census bureau      | 24198   | 7.7811 | Нет           |
| square mile        | 21891   | 9.2054 | Нет           |
| population density | 21185   | 6.9827 | Нет           |
| housing units      | 19597   | 9.8318 | Нет           |
| racial makeup      | 19168   | 9.9902 | Нет           |
| per square         | 21561   | 9.0869 | Нет           |
| total area         | 25302   | 8.2083 | Нет           |

Такой критерий лучше отделяет реально содержательные словосочетания от служебных пар. Среди отобранных биграмм особенно полезными для индекса выглядят `united states`, `according to`, `2010 census`, `population was` и другие устойчивые сочетания с высокой ассоциацией.

## 6. Сравнение способов нормализации текста

| Версия               | Число документов | Размер коллекции в токенах | Средняя длина документа | Число уникальных то |
|----------------------|------------------|----------------------------|-------------------------|---------------------|
| Исходная коллекция   | 99 987           | 19 963 076                 | 199.657                 | 285 376             |
| Стемминг (Porter)    | 99 987           | 19 963 076                 | 199.657                 | 235 971             |
| Лемматизация (spaCy) | 99 987           | 19 965 288                 | 199.679                 | 264 450             |
| BERT-токенизация     | 99 987           | 21 931 437                 | 219.343                 | 27 426              |



Стемминг через Porter сокращает словарь сильнее всего: с 285 376 до 235 971, то есть примерно на 17.31%. Лемматизация через spaCy уменьшает словарь мягче, до 264 450, то есть примерно на 7.33%. BERT-токенизация дает принципиально другой эффект: словарь резко сжимается до 27 426, но средняя длина документа возрастает до 219.3429, потому что слова разбиваются на подслова.

## 7. Итоговые выводы

- Коллекция WikIR\_en1k демонстрирует типичную для IR-корпусов структуру: тяжелый хвост распределения слов, большое число редких токенов и высокую долю stopwords.
- Законы Ципфа и Хипса на данных подтверждаются визуально: это согласуется с ожидаемым поведением естественного текста в больших коллекциях.
- Для биграмм одной частоты недостаточно: нужны формальные критерии на основе частоты, stopwords и ассоциативной меры вроде PMI.
- Стеemming сильнее всего сжимает словарь, лемматизация делает это аккуратнее, а BERT-токенизация не является прямой заменой словарной нормализации, потому что переходит к subword-представлению.