

Отчет по дополнительной задаче: Толстой и Достоевский

1. Постановка задачи

В этой задаче нужно сравнить словарное поведение двух авторов на материале Войны и мира Льва Толстого и Братьев Карамазовых Федора Достоевского. Нас интересуют три вещи: рост словаря в исходных текстах, влияние случайного перемешивания токенов и наиболее характерные слова каждого автора.


Важно, что анализ проводится не по всему творчеству авторов, а по выбранным романам. Поэтому результаты ниже отражают одновременно и авторскую манеру, и лексику конкретных произведений.

2. Базовые статистики

Автор	Токены	Уникальные слова	Type-token ratio	Средняя длина токена
Толстой	531 443	52 075	0.098	5.0647
Достоевский	297 011	35 929	0.121	4.7825

В абсолютном размере словарь Толстого больше, но относительная лексическая насыщенность по type-token ratio выше у Достоевского.

3. Рост словаря в исходных текстах




На исходных текстах кривые растут неравномерно: это означает, что новые слова приходят не случайным равномерным потоком, а блоками, связанными со сценами, персонажами и тематическими переходами.

4. Рост словаря после перемешивания




После случайного перемешивания токенов рост словаря становится более гладким. На отметке около 100 000 токенов shuffled-версия дает словарь больше на 1663 слова у Толстого и на 547 слов у Достоевского. Максимальный разрыв между shuffled и исходной кривой достигает 1819 и 937 слов соответственно.

5. Наиболее характерные слова авторов



Слово	Скор	Частота у Толстого	Частота у Достоевского
пьер	6.8691	1574	0
пьера	5.9123	604	0
ростов	5.909	602	0
княжна	5.8973	595	0
князь	5.7819	1592	2
граф	5.7177	497	0
кутузов	5.3707	351	0
денисов	5.3152	332	0
графиня	5.3092	330	0
французов	5.2241	303	0



Слово	Скор	Частота у Толстого	Частота у Достоевского
алеша	-7.2717	0	878
митя	-6.19	1	595
смердяков	-5.986	0	242
грушенька	-5.811	0	203
старец	-5.4202	0	137
воскликнул	-5.3371	0	126
дескать	-5.2378	0	114
карамазов	-5.2291	0	113
федоровича	-5.2024	0	110
мити	-5.1934	0	109

После очистки технического шума у Толстого особенно выделяются слова пьер, пьера, ростов, княжна, князь, граф, кутузов, а у Достоевского — алеша, митя, смердяков, грушенька, старец, карамазов, раkitин.

6. Сравнение словарей после лемматизации

Дополнительно провел анализ на уровне лемм. Чтобы посмотреть, насколько сильно морфология раздувает исходный словарь.

Автор	Токены	Уникальные словоформы	Уникальные леммы	Сокращение словаря	Сокращение, %
Толстой	531 443	52 075	18 634	33 441	64.22
Достоевский	297 011	35 929	14 426	21 503	59.85

После лемматизации словарь Толстого сокращается сильнее в абсолютном выражении, потому что у него изначально больше словоформ. При этом у обоих авторов заметная часть различий между словоформами схлопывается в общие леммы.

Наиболее характерные леммы Толстого

Лемма	Скор	Частота у Толстого	Частота у Достоевского
пьер	7.2899	2534	0
княжна	6.3756	1015	0
ростов	6.3272	967	0
граф	6.0931	765	0
войско	5.9118	638	0
денисов	5.7799	559	0
сражение	5.7799	559	0
графиня	5.7472	541	0
соня	5.7153	524	0
князь	5.6733	2516	4

Наиболее характерные леммы Достоевского

Лемма	Скор	Частота у Толстого	Частота у Достоевского
алеш	-6.9425	1	1196
митя	-6.6223	1	868
смердяков	-6.4987	0	383
грушенек	-6.0893	0	254
карамазов	-5.7466	0	180
пан	-5.6107	0	157
раkitин	-5.585	0	153
старец	-5.562	1	300
дескать	-5.293	0	114
илюша	-5.2755	0	112

После лемматизации видно, что формы типа пьер и пьера или алеша и алеши схлопываются, поэтому сравнение становится немного ближе к тематическому и понятийному уровню, а не к чистой словоформенной поверхности текста.

При этом автоматическая лемматизация художественного текста и имен собственных неидеальна: для некоторых форм появляются артефакты вроде алеш или грушенек. Поэтому лемматизированный анализ здесь полезен именно как дополнительное сравнение словаря, а не как абсолютно точное представление авторской лексики.

7. Итоговые выводы

- Словарь Толстого в выбранных текстах больше в абсолютном размере, но у Достоевского выше относительная лексическая насыщенность.
- Перемешивание токенов меняет форму кривой роста словаря: это подтверждает, что распределение слов по тексту неслучайно.
- Лемматизация заметно сокращает словарь у обоих авторов и показывает, какая часть различий объясняется морфологическими вариантами слов.
- Списки характерных слов и лемм хорошо отделяют лексические миры романов, но отражают не столько авторский стиль, сколько содержание конкретных произведений.