

Отчет по дополнительной задаче: детекция искусственно сгенерированных текстов

1. Постановка задачи


В этой задаче требуется различать тексты, написанные человеком, и машинно-сгенерированные тексты на материале корпуса CoAT в конфигурации `binary`.

Работа построена как baseline-анализ: сначала рассматриваются простые свойства датасета и текста, затем обучаются две модели — на лексических агрегатах и на TF-IDF признаках.

2. Структура датасета

Сплит	Число текстов
train	172 398
validation	24 628
test	48 714

Класс	Доля
0	0.5
1	0.5



Обучающая выборка полностью сбалансирована: в `train` одинаковое число текстов обоих классов.

3. Длины текстов и простые признаки

Сплит	Средняя длина в символах	Средняя длина в словах	Медианная длина в словах
train	292.06	39.614	20
validation	296.333	40.183	20
test	330.073	44.316	20




Средние лексические признаки по train:

Класс	token_count	unique_count	avg_token_length	type_token_ratio	hapax_ratio	digit_share
0	33.2444	28.1078	6.0746	0.9249	0.934	0.0128
1	43.9255	41.2595	5.9109	0.9432	0.9426	0.0121


У класса 1 тексты в среднем длиннее и показывают более высокие `unique_count`, `type_token_ratio` и `hapax_ratio`. Значит, даже простые агрегированные характеристики уже содержат полезный сигнал для классификации.


4. Baseline-модели

Модель	Val accuracy	Val macro F1	Test accuracy	Test macro F1
Лексические признаки	0.6206	0.6203	—	—
TF-IDF + LogisticRegression	0.7161	0.7157	—	—



Confusion matrix: validation, лексические признаки





Модель на простых лексических признаках дает $\text{Val macro F1} = 0.6203$, а модель TF-IDF + LogisticRegression заметно сильнее и достигает 0.7157.

5. Особенность test-сплита

У опубликованного test-сплита в конфигурации `binary` нет истинных меток: там во всех строках `label = -1`. Поэтому корректно считать тестовые `accuracy` и `F1` здесь нельзя; вместо этого можно анализировать только предсказания моделей на `test`.

Модель	Доля предсказаний класса 0	Доля предсказаний класса 1
Лексические признаки	0.5574	0.4426
TF-IDF + LogisticRegression	0.5284	0.4716

На неразмеченном `test` модель на лексических признаках относит примерно 44.26% текстов к классу 1, а TF-IDF-модель — примерно 47.16%.

6. Итоговые выводы

- Простые статистические признаки текста дают рабочий `baseline`, но заметно уступают частотной модели на словах и биграммах.
- Для задачи детекции важны не только длина и разнообразие словаря, но и конкретное содержимое текста.
- Даже линейная модель на TF-IDF показывает, что у `human` и `generated` текстов есть устойчивые различия, заметные уже без сложных нейросетевых моделей.
- При интерпретации результатов важно учитывать, что `test-сплит` в текущей конфигурации не размечен.