

Отчет по дополнительной задаче: коллекция MIRAGE

1. Постановка

Нужно адаптировать MIRAGE к IR-постановке:

- собрать единый корпус фрагментов;
- построить qrels;
- запустить tf-idf и BM25;
- оценить качество;
- сравнить результаты с WikIR.

2. Данные и преобразование коллекции

Сводка по коллекции:

Показатель	Значение
Число запросов	7,560
Число уникальных фрагментов	37,799
Число qrels	9,268
Средняя длина запроса	8.74 слова
Среднее число релевантных фрагментов на запрос	1.23
Средний размер пула кандидатов	5.0




Рис. 1: Распределение длины запросов в MIRAGE

3. Методика

Использованы те же два метода, что и в основной части: tf-idf и BM25. И те же три варианта предобработки: original, stemmed, lemmatized.




Рис. 2: Число релевантных фрагментов на запрос в MIRAGE

Метрики: $P@1$, $P@10$, $P@20$, AP, $nDCG@20$

Из инженерных улучшений:

- для поиска по фрагментам использовал эквивалентную разреженную реализацию формулы BM25, потому что прямой вызов `rank_bm25.get_scores` для каждого запроса на полном корпусе оказывался слишком дорогим;
- это не меняет саму модель, но делает воспроизводимый полный базовый прогон практически выполнимым по времени.

4. Результаты

Сводная таблица базовых прогонов:

Метод	Вариант	$P@1$	$P@10$	$P@20$	AP	$nDCG@20$	Среднее время на запрос, сек
tf-idf	original	0.1295	0.0362	0.0209	0.1847	0.2242	0.00108
tf-idf	stemmed	0.2131	0.0550	0.0308	0.2939	0.3488	0.00091
tf-idf	lemmatized	0.1946	0.0533	0.0312	0.2748	0.3325	0.00162
BM25	original	0.2128	0.0426	0.0233	0.2565	0.2902	0.00108
BM25	stemmed	0.3466	0.0651	0.0346	0.4106	0.4555	0.00080
BM25	lemmatized	0.3044	0.0594	0.0325	0.3620	0.4061	0.00134




Рис. 3: Сравнение метрик в MIRAGE




Рис. 4: Среднее время ответа на запрос в MIRAGE

Основные наблюдения:

- BM25 лучше tf-idf на всех трех вариантах текста.
- Лучший базовый вариант на MIRAGE это BM25 + stemmed.
- Морфологическая нормализация на MIRAGE помогает намного сильнее, чем на WikIR.
- stemmed стабильно сильнее lemmatized.
- Время поиска почти одинаково для всех вариантов; основная цена морфологии лежит в preprocess_seconds, а не в самом ранжировании.

5. Анализ по отдельным запросам и разбор ошибок

Отдельно разобрал лучший базовый вариант BM25 + stemmed на уровне отдельных запросов.

5.1. Какие запросы легче и труднее

По источникам вопросов картина неоднородна:

Источник	Запросов	Средний AP	Средний nDCG@20	Средний P@1	Средняя длина
ifqa	248	0.8477	0.8805	0.7782	22.44
triviaqa	584	0.5438	0.6032	0.5068	13.28
naturalqa	3,578	0.5337	0.5960	0.4346	8.87
drop	75	0.3428	0.3717	0.2933	8.65
popqa	3,075	0.2084	0.2317	0.1802	6.64




Рис. 5: Средний AP по источникам запросов в MIRAGE

Ключевой вывод здесь простой:

- самые легкие запросы приходят из ifqa, где вопросы длинные, конкретные и содержат много хорошо различающих терминов;
- самые трудные запросы это popqa, где формулировки короткие и часто похожи на шаблон "Who was the director/author/producer of X?";
- naturalqa в среднем заметно сильнее popqa, но внутри него много нулевых случаев из-за неоднозначности сущностей.

Эффект длины запроса тоже сильный:

Группа по длине запроса	Запросов	Средний AP	Средний nDCG@20	Средний P@1
11+	1,085	0.6635	0.7206	0.5889
6-10	6,088	0.3849	0.4284	0.3208
<=5	387	0.1061	0.1395	0.0724

Это хорошо согласуется с интуитивной оценкой: чем длиннее и конкретнее запрос, тем проще лексической модели выделить правильный фрагмент.

5.2. Легкие и трудные запросы

В mirage_easy_queries_bm25_stemmed.csv много запросов с AP = 1.0. Обычно это вопросы, где:

- есть редкое имя, дата или точное название;




Рис. 6: Средний AP по длине запросов в MIRAGE

- правильный фрагмент содержит почти буквальное лексическое совпадение;
- в пуле из пяти фрагментов нет сильных конкурирующих сущностей.

В `mirage_hard_queries_bm25_stemmed.csv` наоборот доминируют $AP = 0.0$ кейсы. Типичный профиль такого запроса:

- короткая формулировка;
- одно смысловое ядро вроде `director, author, producer`;
- неоднозначная хвостовая часть запроса, которая совпадает с множеством заглавий или близких по названию фрагментов.

5.3. Типичные ошибки

В `mirage_error_cases_bm25_stemmed.csv` видны три повторяющихся типа ошибок:

1. Запрос попадает в страницу с похожим названием, но не во фрагмент с нужным ответом. Пример: `who sang i was kaiser bill's batman` уходит в страницу про альбом, а не во фрагмент с нужным исполнителем.
2. Срабатывает совпадение по странице-развилке или по заглавию. Пример: `a sound of thunder ...` попадает во фрагмент `Sound of Thunder`, похожий на страницу-развилку.
3. Модель переоценивает локальное лексическое совпадение по яркому токenu. Пример: `who sings zoom zoom zoom and a boom boom` уходит в `Hunter Zolomon`, потому что редкий фрагмент запроса не связан с реальной сущностью, содержащей ответ.

Эти случаи подтверждают, что для MIRAGE главный предел базового решения не в общей силе BM25, а в снятии неоднозначности сущностей и в совпадениях по заглавиям.

6. Сравнение с WikIR

Для сравнения беру базовый результат из основной части:

- лучший базовый вариант на WikIR: BM25 + stemmed, $AP = 0.2020$, $nDCG@20 = 0.3892$

- лучший базовый вариант на MIRAGE: BM25 + stemmed, AP = 0.4106, nDCG@20 = 0.4555

Что важно интерпретировать аккуратно:

- абсолютные значения между коллекциями в прямом сравнении неэквивалентны, потому что у MIRAGE иная разметка, поиск ведётся по фрагментам, и положительных фрагментов на запрос очень мало;
- зато относительный паттерн устойчив:
 - BM25 > tf-idf
 - stemmed > lemmatized > original по качеству

Главное отличие между коллекциями:

- на WikIR стемминг давал небольшой, но устойчивый прирост;
- на MIRAGE стемминг даёт большой прирост почти по всем метрикам.

Правдоподобное объяснение:

- WikIR уже довольно чисто подготовлен и состоит из полнотекстовых статей;
- MIRAGE работает на уровне коротких фрагментов и более длинных запросов;
- из-за этого точность лексического сопоставления и нормализация словоформ играют большую роль.

7. Выводы

1. Качество очень сильно зависит от типа источника: ifqa почти решается базовой моделью, а rorqa заметно сложнее.
2. Длина запроса здесь особенно важна: короткие вопросы деградируют на порядок сильнее длинных.
3. Основные ошибки связаны не с отсутствием лексического совпадения, а с неоднозначностью при сопоставлении сущностей и заголовков, а также с близкими, но нерелевантными фрагментами.

По идее, улучшить результат можно действуя следующим образом:

1. Добавить переранжирование или лёгкое снятие неоднозначности сущностей поверх верхних фрагментов.
2. Проверить, как влияет удаление дублей фрагментов и группировка на уровне статей.
3. Добавить настроенный BM25 и сравнить, переносится ли выигрыш между WikIR и MIRAGE.

Отчет по дополнительной задаче: Толстой и Достоевский

1. Постановка

Нужно:

- разбить два романа из прошлого ДЗ на абзацы;
- найти наиболее похожие абзацы внутри каждого романа;
- найти наиболее похожие абзацы между двумя романами;
- сравнить tf-idf и BM25;
- обосновать выбор idf-схемы для этой задачи.

2. Данные и подготовка корпуса

Подготовка корпуса:

1. HTML/SHTML-файлы декодированы из cp1251.
2. Выделены блоки dd/h4.
3. Убраны служебные фрагменты сайта, явные комментарии и редакторский мусор.
4. Каждый абзац получил устойчивый идентификатор.

Итоговая сводка:

Автор	Роман	Абзацы	Среднее число токенов	Медиана числа токенов
tolstoy	War and Peace	8,313	53.39	36
dostoevsky	The Brothers Karamazov	3,256	87.36	35




Рис. 7: Распределение длины абзацев

У Достоевского абзацы в среднем заметно длиннее, чем у Толстого, а значит и лексическое перекрытие внутри романа у него должно быть стабильнее.

3. Методика поиска похожих абзацев

Использованы четыре поисковые постановки: `within_tolstoy`, `within_dostoevsky`, `tolstoy_to_dostoevsky`, `dostoevsky_to_tolstoy`.

Модели: `tf-idf`, `BM25`.

Для вопроса об `idf` сравнивал:

- `tf-idf + global idf`
- `tf-idf + local idf`

`BM25` использовал в основной постановке с общим корпусом как более естественная модель для поиска по объединённому корпусу абзацев.

4. Результаты

Сводка по лучшему совпадению для каждого запроса:

Постановка	Метод	IDF	Среднее top-1	Медиана top-1	P90 top-1
Внутри Толстого	tf-idf	global	0.2094	0.1932	0.2992
Внутри Толстого	tf-idf	local	0.2099	0.1935	0.3012
Внутри Толстого	BM25	global	47.9899	36.9038	84.8026
Внутри Достоевского	tf-idf	global	0.2358	0.2208	0.3370
Внутри Достоевского	tf-idf	local	0.2304	0.2160	0.3330
Внутри Достоевского	BM25	global	64.7192	37.7758	130.3298
Толстой -> Достоевский	tf-idf	global	0.1469	0.1381	0.2150
Толстой -> Достоевский	tf-idf	local	0.1872	0.1785	0.2570
Толстой -> Достоевский	BM25	global	31.5679	24.4404	56.1325
Достоевский -> Толстой	tf-idf	global	0.1790	0.1692	0.2512
Достоевский -> Толстой	tf-idf	local	0.2160	0.2055	0.2981
Достоевский -> Толстой	BM25	global	50.3146	29.1952	101.4532




Рис. 8: Сравнение top-1 оценок

Основные наблюдения:

- внутри романов сходство выше, чем между романами;
- у Достоевского внутри-романная близость выше, чем у Толстого;
- BM25 дает более сильные лексические совпадения, чем tf-idf;

- между романами совпадения существуют, но в среднем они слабее совпадений внутри одного романа, что как будто бы и так интуитивно понятно :О)

5. Анализ idf

Сравнение `global` и `local` idf показывает две разные картины:

1. Для поиска внутри одного романа разница почти исчезает. Для Толстого:

- 0.2094 против 0.2099

Для Достоевского: - 0.2358 против 0.2304

То есть внутри одного романа выбор idf-схемы почти не меняет результат.

2. Для поиска между романами `local` idf у `tf-idf` заметно сильнее. Например:

- `tolstoy_to_dostoevsky`: 0.1469 → 0.1872
- `dostoevsky_to_tolstoy`: 0.1790 → 0.2160

Интерпретация:

- `global` idf лучше отражает единую редкость слов на объединенном корпусе;
- `local` idf сильнее подчеркивает слова, редкие именно в целевом романе;
- поэтому для межроманного поиска он даёт более жёсткое различие по словам.

Мой практический вывод такой:

- если цель в единой постановке и сопоставимости внутри и между романами, я бы использовал `global` idf;
- если цель именно в поиске наилучших межроманных лексических совпадений, `local` idf у `tf-idf` выглядит сильнее.

Это хорошо видно на графике:




Рис. 9: Сравнение схем IDF

6. Ручной анализ лучших межроманных пар

Чтобы проверить, насколько лучшие межроманные пары действительно содержательны, а не только лексически похожи, я вручную разобрал 12 сильных пар из направлений `tolstoy_to_dostoevsky` и `dostoevsky_to_tolstoy`.

Артефакты:

- manual_cross_book_analysis.csv
- manual_cross_book_category_summary.csv
- manual_cross_book_assessment_summary.csv

Сводка по категориям:

Категория	Пар
Поверхностно-лексические	5
Неоднозначные	3
Тематические	4

Сводка по силе совпадения:

Оценка силы совпадения	Пар
Слабые	5
Средние	5
Сильные	2




Рис. 10: Категории лучших межроманных пар

Что это показывает:

- самая частая категория это поверхностно-лексические совпадения: французские вставки, формульные обращения, риторические повторы, междометия и смеховые маркеры вроде ха-ха;
- еще часть совпадений неоднозначна: лексическое перекрытие заметно, и некоторая тематическая близость тоже есть, но она строится на слишком общей эмоциональной или риторической лексике;

- при этом есть и действительно тематические пары, где совпадают мотивы долга, религиозного объяснения страдания, внутреннего суда над собой и моральной обязанности.

Практический смысл, который можно вынести из этого разбора:

- BM25 и tf-idf действительно находят небесмысленные межроманные параллели;
- но без ручной проверки их нельзя автоматически считать семантическими аналогами;
- лучшее лексическое совпадение между романами часто оказывается стилистическим или формульным, а не содержательно близким.

То есть чисто поисковая постановка здесь полезна скорее как инструмент отбора кандидатов для последующего литературного анализа, а не как готовый детектор истинных тематических параллелей.

7. Выводы

1. Наиболее сильные совпадения внутри одного романа часто возникают там, где есть длинные письма, монологи или повторно обсуждаемые сюжетные эпизоды.
2. Между романами лексическое сходство тоже есть, но ручной анализ показывает смешанную картину: часть совпадений поверхностна, часть действительно тематична.
3. Это значит, что чисто лексические методы хорошо ловят кандидатов на межтекстовые параллели, но не гарантируют смысловой эквивалентности.

Если улучшать решение дальше, самые разумные направления такие:

1. Расширить ручную разметку с 12 пар до нескольких десятков и посчитать долю действительно тематических совпадений отдельно для BM25 и tf-idf.
2. Разделить повествовательный текст и редакторские / вставные блоки еще жестче.
3. Проверить сегментацию по предложениям, а не по абзацам, для более тонких совпадений.