

Отчет по дополнительной задаче: коллекция MIRAGE

1. Постановка

Нужно адаптировать MIRAGE к IR-постановке:

- собрать единый корпус фрагментов;
- построить qrels;
- запустить tf-idf и BM25;
- оценить качество;
- сравнить результаты с WikIR.

2. Данные и преобразование коллекции

Сводка по коллекции:

Показатель	Значение
Число запросов	7,560
Число уникальных фрагментов	37,799
Число qrels	9,268
Средняя длина запроса	8.74 слова
Среднее число релевантных фрагментов на запрос	1.23
Средний размер пула кандидатов	5.0




Рис. 1: Распределение длины запросов в MIRAGE

3. Методика

Использованы те же два метода, что и в основной части: tf-idf и BM25. И те же три варианта предобработки: original, stemmed, lemmatized.




Рис. 2: Число релевантных фрагментов на запрос в MIRAGE

Метрики: $P@1$, $P@10$, $P@20$, AP, $nDCG@20$

Из инженерных улучшений:

- для поиска по фрагментам использовал эквивалентную разреженную реализацию формулы BM25, потому что прямой вызов `rank_bm25.get_scores` для каждого запроса на полном корпусе оказывался слишком дорогим;
- это не меняет саму модель, но делает воспроизводимый полный базовый прогон практически выполнимым по времени.

4. Результаты

Сводная таблица базовых прогонов:

Метод	Вариант	$P@1$	$P@10$	$P@20$	AP	$nDCG@20$	Среднее время на запрос, сек
tf-idf	original	0.1295	0.0362	0.0209	0.1847	0.2242	0.00108
tf-idf	stemmed	0.2131	0.0550	0.0308	0.2939	0.3488	0.00091
tf-idf	lemmatized	0.1946	0.0533	0.0312	0.2748	0.3325	0.00162
BM25	original	0.2128	0.0426	0.0233	0.2565	0.2902	0.00108
BM25	stemmed	0.3466	0.0651	0.0346	0.4106	0.4555	0.00080
BM25	lemmatized	0.3044	0.0594	0.0325	0.3620	0.4061	0.00134




Рис. 3: Сравнение метрик в MIRAGE




Рис. 4: Среднее время ответа на запрос в MIRAGE

Основные наблюдения:

- BM25 лучше tf-idf на всех трех вариантах текста.
- Лучший базовый вариант на MIRAGE это BM25 + stemmed.
- Морфологическая нормализация на MIRAGE помогает намного сильнее, чем на WikIR.
- stemmed стабильно сильнее lemmatized.
- Время поиска почти одинаково для всех вариантов; основная цена морфологии лежит в preprocess_seconds, а не в самом ранжировании.

5. Анализ по отдельным запросам и разбор ошибок

Отдельно разобрал лучший базовый вариант BM25 + stemmed на уровне отдельных запросов.

5.1. Какие запросы легче и труднее

По источникам вопросов картина неоднородна:

Источник	Запросов	Средний AP	Средний nDCG@20	Средний P@1	Средняя длина
ifqa	248	0.8477	0.8805	0.7782	22.44
triviaqa	584	0.5438	0.6032	0.5068	13.28
naturalqa	3,578	0.5337	0.5960	0.4346	8.87
drop	75	0.3428	0.3717	0.2933	8.65
popqa	3,075	0.2084	0.2317	0.1802	6.64




Рис. 5: Средний AP по источникам запросов в MIRAGE

Ключевой вывод здесь простой:

- самые легкие запросы приходят из ifqa, где вопросы длинные, конкретные и содержат много хорошо различающих терминов;
- самые трудные запросы это popqa, где формулировки короткие и часто похожи на шаблон "Who was the director/author/producer of X?";
- naturalqa в среднем заметно сильнее popqa, но внутри него много нулевых случаев из-за неоднозначности сущностей.

Эффект длины запроса тоже сильный:

Группа по длине запроса	Запросов	Средний AP	Средний nDCG@20	Средний P@1
11+	1,085	0.6635	0.7206	0.5889
6-10	6,088	0.3849	0.4284	0.3208
<=5	387	0.1061	0.1395	0.0724

Это хорошо согласуется с интуитивной оценкой: чем длиннее и конкретнее запрос, тем проще лексической модели выделить правильный фрагмент.

5.2. Легкие и трудные запросы

В mirage_easy_queries_bm25_stemmed.csv много запросов с AP = 1.0. Обычно это вопросы, где:

- есть редкое имя, дата или точное название;




Рис. 6: Средний AP по длине запросов в MIRAGE

- правильный фрагмент содержит почти буквальное лексическое совпадение;
- в пуле из пяти фрагментов нет сильных конкурирующих сущностей.

В `mirage_hard_queries_bm25_stemmed.csv` наоборот доминируют $AP = 0.0$ кейсы. Типичный профиль такого запроса:

- короткая формулировка;
- одно смысловое ядро вроде `director, author, producer`;
- неоднозначная хвостовая часть запроса, которая совпадает с множеством заглавий или близких по названию фрагментов.

5.3. Типичные ошибки

В `mirage_error_cases_bm25_stemmed.csv` видны три повторяющихся типа ошибок:

1. Запрос попадает в страницу с похожим названием, но не во фрагмент с нужным ответом. Пример: `who sang i was kaiser bill's batman` уходит в страницу про альбом, а не во фрагмент с нужным исполнителем.
2. Срабатывает совпадение по странице-развилке или по заглавию. Пример: `a sound of thunder ...` попадает во фрагмент `Sound of Thunder`, похожий на страницу-развилку.
3. Модель переоценивает локальное лексическое совпадение по яркому токenu. Пример: `who sings zoom zoom zoom and a boom boom` уходит в `Hunter Zolomon`, потому что редкий фрагмент запроса не связан с реальной сущностью, содержащей ответ.

Эти случаи подтверждают, что для MIRAGE главный предел базового решения не в общей силе BM25, а в снятии неоднозначности сущностей и в совпадениях по заглавиям.

6. Сравнение с WikIR

Для сравнения беру базовый результат из основной части:

- лучший базовый вариант на WikIR: BM25 + stemmed, $AP = 0.2020$, $nDCG@20 = 0.3892$

- лучший базовый вариант на MIRAGE: BM25 + stemmed, AP = 0.4106, nDCG@20 = 0.4555

Что важно интерпретировать аккуратно:

- абсолютные значения между коллекциями в прямом сравнении неэквивалентны, потому что у MIRAGE иная разметка, поиск ведётся по фрагментам, и положительных фрагментов на запрос очень мало;
- зато относительный паттерн устойчив:
 - BM25 > tf-idf
 - stemmed > lemmatized > original по качеству

Главное отличие между коллекциями:

- на WikIR стемминг давал небольшой, но устойчивый прирост;
- на MIRAGE стемминг даёт большой прирост почти по всем метрикам.

Правдоподобное объяснение:

- WikIR уже довольно чисто подготовлен и состоит из полнотекстовых статей;
- MIRAGE работает на уровне коротких фрагментов и более длинных запросов;
- из-за этого точность лексического сопоставления и нормализация словоформ играют большую роль.

7. Выводы

1. Качество очень сильно зависит от типа источника: ifqa почти решается базовой моделью, а rorqa заметно сложнее.
2. Длина запроса здесь особенно важна: короткие вопросы деградируют на порядок сильнее длинных.
3. Основные ошибки связаны не с отсутствием лексического совпадения, а с неоднозначностью при сопоставлении сущностей и заголовков, а также с близкими, но нерелевантными фрагментами.

По идее, улучшить результат можно действуя следующим образом:

1. Добавить переранжирование или лёгкое снятие неоднозначности сущностей поверх верхних фрагментов.
2. Проверить, как влияет удаление дублей фрагментов и группировка на уровне статей.
3. Добавить настроенный BM25 и сравнить, переносится ли выигрыш между WikIR и MIRAGE.