

DZ3: обучение ранжированию

Подпункт	Статус	Подтверждение
0.1. Повторить градиентный бустинг	выполнено	использован CatBoostRanker во всех экспериментах
0.2. Изучить и установить CatBoost	выполнено	CatBoost использован в разделах 1, 2, 3, 4
0.3. Изучить описание LETOR	выполнено	раздел 1 реализован на данных MSRank / LETOR
1. CatBoost на MS LETOR	выполнено	artifacts/msrank/results.md
2.1. Привести Internet Mathematics 2009 к формату LETOR и описать данные	выполнено	artifacts/processed/imat2009_summary.md
2.2. Не менее двух методов с NDCG	выполнено	artifacts/imat2009/results.md
3.1. Улучшение BM25 на WikIR	выполнено	artifacts/wikir_ltr/results.md
3.2. Восстановление BM25 по компонентам	выполнено	artifacts/wikir_ltr/results.md
4.1. Разбиение MIRAGE с учетом происхождения вопросов	выполнено	artifacts/mirage_ltr/results.md
4.2. Двухпольное представление + просмотры + входящие ссылки + признаки из 3.1	выполнено	artifacts/mirage_ltr/wiki_signals.csv и scripts/run_mirage_ltr.py
4.3. Обучение, оценка и анализ на MIRAGE	выполнено	artifacts/mirage_ltr/results.md

1. MS LETOR

Для этого раздела использовал набор `msrank_10k`, который совместим с LETOR и позволяет воспроизвести стандартный пример применения CatBoost к задаче обучения ранжированию. Из обучающей части была выделена отдельная валидационная подвыборка по группам запросов, после чего обучал модель YetiRank. Настройка модели идёт по валидации, а тест используется только для финальной проверки качества.

Метрика	Валидация	Тест
AP	0.63146	0.56187
NDCG@10	0.41637	0.39897
NDCG@20	0.45579	0.43856

2. Internet Mathematics 2009

В Internet Mathematics 2009 исходные строки уже содержали разреженные признаки и метку релевантности, но идентификатор запроса находился не в поле `qid`, а в комментарии после `#`. Поэтому первым шагом данные были приведены к LETOR-совместимому виду с явным `qid`, после чего была собрана статистика по числу запросов, размеру групп и плотности матрицы признаков. Далее проверил два ранжирующих варианта на CatBoost: YetiRank и PairLogit. В обоих случаях целевой метрикой служила NDCG, а подбор числа итераций выполнялся по отдельной валидации.

Лучший метод: `catboost_yetirank`.

Модель	NDCG@5	NDCG@10	NDCG@20
catboost_yetirank	0.71979	0.76753	0.78650
catboost_pairlogit	0.71055	0.76182	0.78140

Обе модели дают близкое качество, однако YetiRank немного превосходит PairLogit по всем значениям NDCG, поэтому именно его было бы разумно считать базовым решением для этого набора.




Figure 1: Сравнение моделей на Internet Mathematics 2009

3. WikIR

Здесь реализовал оба подпункта задания. Для пункта 3.1 к исходному BM25 добавил признаки, описывающие пару запрос-документ: длина запроса, число совпавших терминов, сумма и максимум частот, сумма и максимум *idf*, доля покрытия запроса, расстояние между совпавшими терминами и совпадения биграмм. Обучающая выборка строилась из релевантных документов и такого же числа нерелевантных документов для каждого запроса, причём отрицательные примеры брались из верхней части выдачи BM25, чтобы задача оставалась содержательной. Для пункта 3.2 отдельно построил модель, которая использует только компоненты, лежащие в основе BM25: частоты терминов, *idf* и длину документа.

Лучшая модель ранжирования: CatBoost с расширенными признаками (PairLogit) с $NDCG@20 = 0.47733$.

Система	AP	NDCG@20
BM25 по верхним 100 документам	0.31670	0.42016
Лучший BM25 из Д32	0.20204	0.38918
CatBoost с расширенными признаками (YetiRank)	0.25079	0.32417
CatBoost с расширенными признаками (PairLogit)	0.36526	0.47733
CatBoost по компонентам BM25	0.33189	0.41927

Выводы здесь можно сделать такие. Во-первых, расширенный набор признаков в сочетании с PairLogit действительно улучшает базовый BM25 и заметно превосходит как top-100 базу, так и лучший результат из Д32. Во-вторых, модель по компонентам BM25 почти воспроизводит исходный BM25, но не даёт такого выигрыша, как более богатое описание пары запрос-документ.

4. MIRAGE

Для MIRAGE сначала построил стратифицированное разбиение по полю *source*, чтобы в обучении, валидации и тесте сохранялось происхождение вопросов из разных подколлекций. Каждый кандидатный фрагмент рассматривался как двухпольный документ: отдельно вычислялись признаки по заголовку страницы




Figure 2: Сравнение систем на WikIR

и по основному тексту фрагмента. Это прямо соответствует формулировке задания. Дополнительно были собраны внешние признаки страницы из Wikipedia: суммарные просмотры за последние 12 месяцев, среднее число просмотров в месяц, число входящих ссылок и число перенаправлений. Финальная улучшенная модель объединяет эти сигналы с лексическими признаками из пункта 3.1 и сравнивается с более простой лексической базой.

Лучшая модель ранжирования: Модель с признаками заголовка, текста и сигналами Wikipedia с $NDCG@5 = 0.80551$.

Модель	AP	NDCG@3	NDCG@5
Лексическая модель ранжирования	0.69796	0.70419	0.77774
Модель с признаками заголовка, текста и сигналами Wikipedia	0.73564	0.74707	0.80551

Здесь улучшенная модель выигрывает у лексической базы по всем показателям. Это важно, потому что прирост достигается не только за счёт текстовых совпадений, но и за счёт структуры страницы и внешних сигналов популярности и связности.




Figure 3: Сравнение моделей на MIRAGE