

DZ4: нейросетевой поиск и переупорядочивание

Данные и постановка эксперимента

- Используются оба корпуса из условия: WikIR en1k и MIRAGE.
- Для WikIR использованы готовые обучающая и тестовая части.
- Для MIRAGE тестовая часть воспроизведена тем же стратифицированным разбиением по полю source, что и в dz3.
- Во всех основных конфигурациях считаются метрики P@1, P@10, P@20, MAP@20, nDCG@20.

Выбор моделей

- all-MiniLM-L6-v2 выбрана как компактная и быстрая модель, удобная как сильная базовая точка для смыслового поиска.
- paraphrase-multilingual-MiniLM-L12-v2 выбрана как более крупная многоязычная модель, чтобы проверить, даст ли более богатое смысловое представление выигрыш на тех же данных.
- Для переупорядочивания использована all-MiniLM-L6-v2. Это разумный компромисс между качеством и временем ответа, но такая схема слабее парной модели, которая оценивает запрос и документ совместно.

Результаты нейросетевого поиска

Набор	Модель	P@1	P@10	P@20	MAP@20	nDCG@20	Среднее время запроса, с
WikIR, тест	all-MiniLM-L6-v2	0.6500	0.2430	0.1705	0.1929	0.4705	0.001630
WikIR, тест	paraphrase-multilingual-MiniLM-L12-v2	0.4400	0.1300	0.0900	0.0952	0.2757	0.001902
MIRAGE, тест	all-MiniLM-L6-v2	0.5922	0.1129	0.0582	0.7039	0.7694	0.000491
MIRAGE, тест	paraphrase-multilingual-MiniLM-L12-v2	0.5109	0.0927	0.0491	0.5841	0.6469	0.000451

Вывод по пункту 1:

- На обоих наборах лучшей оказалась all-MiniLM-L6-v2.
- На WikIR разница особенно велика: по nDCG@20 модель all-MiniLM-L6-v2 даёт 0.4705, тогда как paraphrase-multilingual-MiniLM-L12-v2 даёт только 0.2757.
- На MIRAGE картина такая же: 0.7694 против 0.6469 по nDCG@20.
- По времени ответа обе модели близки, поэтому здесь нет причины предпочесть более слабую модель.

Результаты переупорядочивания

Набор	Модель	k	P@1	P@10	P@20	MAP@20	nDCG@20	Среднее время запроса, с
WikIR, тест	all- MiniLM- L6-v2	10	0.4800	0.1770	0.1295	0.1579	0.3413	0.002299
WikIR, тест	all- MiniLM- L6-v2	20	0.5300	0.2050	0.1295	0.1686	0.3626	0.001258
WikIR, тест	all- MiniLM- L6-v2	50	0.5300	0.2120	0.1365	0.1711	0.3721	0.003336
WikIR, тест	all- MiniLM- L6-v2	100	0.5300	0.2250	0.1465	0.1807	0.3910	0.001426
MIRAGE, тест	all- MiniLM- L6-v2	10	0.4686	0.0742	0.0391	0.5158	0.5524	0.000038
MIRAGE, тест	all- MiniLM- L6-v2	20	0.4812	0.0781	0.0391	0.5316	0.5652	0.000020
MIRAGE, тест	all- MiniLM- L6-v2	50	0.5030	0.0839	0.0423	0.5638	0.6011	0.000405
MIRAGE, тест	all- MiniLM- L6-v2	100	0.5102	0.0859	0.0435	0.5755	0.6145	0.000607

Вывод по пункту 2:

- Лучший результат переупорядочивания по nDCG@20 достигается при $k = 100$ и для WikIR, и для MIRAGE.
- При увеличении k качество растёт, что логично: модель получает больше кандидатов для повторной сортировки.
- При этом даже лучший вариант переупорядочивания уступает чистому нейросетевому поиску.
- На WikIR разница между лучшим нейросетевым поиском и лучшим переупорядочиванием составляет $0.4705 - 0.3910 = 0.0795$ по nDCG@20.
- На MIRAGE разница ещё заметнее: $0.7694 - 0.6145 = 0.1549$ по nDCG@20.

Текущее переупорядочивание не усиливает поиск, а ослабляет его. Причина правдоподобна: мы ограничены кандидатами от BM25, а само переупорядочивание использует ту же косинусную близость, но без более сильной парной модели.

Результаты смешанной модели

- Коэффициент α подбирался на обучающей части WikIR по метрике nDCG@20.
- Перед смешиванием оценки BM25 нормировались отдельно для каждого запроса по схеме min-max в диапазон $[0, 1]$.
- Лучшее значение: $\alpha = 0.1$.

Набор	Модель	alpha	P@1	P@10	P@20	MAP@20	nDCG@20	Среднее время запроса, с
WikIR, тест	all-MiniLM-L6-v2	0.10	0.6800	0.2620	0.1795	0.2105	0.4900	0.000014
MIRAGE, тест	all-MiniLM-L6-v2	0.10	0.6134	0.1141	0.0585	0.7194	0.7820	0.000012

Вывод по пункту 3:

- Смешанная модель оказалась лучшим вариантом среди уже проверенных конфигураций.
- На WikIR она улучшает nDCG@20 относительно лучшего чистого нейросетевого поиска на +0.0195: 0.4705 → 0.4900.
- На MIRAGE улучшение тоже есть: +0.0126: 0.7694 → 0.7820.
- Оптимальное значение alpha = 0.1 означает, что наилучший результат даёт схема, где смысловый сигнал доминирует, а вклад BM25 остаётся вспомогательным.

Подбор коэффициента alpha




Figure 1: Подбор alpha

По кривой видно, что максимум по nDCG@20 достигается вблизи alpha = 0.1. При дальнейшем увеличении доли BM25 качество постепенно снижается, а при alpha = 1.0 результат фактически сводится к чисто лексическому ранжированию и становится существенно слабее.

Эффективность

Время кодирования

Набор	Модель	Кодирование документов, с	Кодирование запросов, с
WikIR	all-MiniLM-L6-v2	6524.29	15.22
WikIR	paraphrase-multilingual-MiniLM-L12-v2	1972.34	0.15
MIRAGE	all-MiniLM-L6-v2	1795.15	2.68
MIRAGE	paraphrase-multilingual-MiniLM-L12-v2	685.50	4.24

Среднее время ответа на запрос

Конфигурация	WikIR, с	MIRAGE, с	Комментарий
Лучший смысловой поиск (all-MiniLM-L6-v2)	0.001630	0.000491	быстрый отклик после подготовки индекса
Вторая модель (paraphrase-multilingual-MiniLM-L12-v2)	0.001902	0.000451	по скорости сопоставима, но слабее по качеству
Лучшее переупорядочивание (k = 100)	0.001426	0.000607	указано время только второй стадии, без получения кандидатов BM25
Смешанная модель (alpha = 0.1)	0.000014	0.000012	самая дешёвая стадия после получения исходных оценок

Вывод по эффективности:

- После подготовки представлений документов все методы работают быстро.
- Время ответа у двух моделей близко, поэтому выбор в пользу all-MiniLM-L6-v2 делается по качеству, а не по скорости.
- Для переупорядочивания в таблице указано время только самой стадии повторной сортировки. Стоимость получения кандидатов BM25 в эти числа не входит.
- Переупорядочивание не даёт выигрыша по качеству, поэтому его дополнительная вычислительная сложность в текущей постановке не оправдывается.
- Смешанная модель почти ничего не стоит по времени и при этом даёт лучший итоговый результат.

Сравнение с dz2 и dz3

- На WikIR лучший BM25 из dz2 давал $nDCG@20 = 0.3892$. Уже чистый нейросетевой поиск поднял это значение до 0.4705, а смешанная модель до 0.4900.
- На MIRAGE лучший BM25 из dz2 давал $nDCG@20 = 0.4555$. Чистый нейросетевой поиск поднял это значение до 0.7694, а смешанная модель до 0.7820.
- Для WikIR есть прямое сравнение с лучшим результатом из dz3: там $nDCG@20 = 0.4773$, а здесь смешанная модель даёт 0.4900, то есть улучшение на +0.0127.
- Для MIRAGE прямое численное сравнение с dz3 ограничено, потому что в dz3 сохранены другие метрики: AP и $nDCG@5$. Сопоставлять их с MAP@20 и $nDCG@20$ напрямую некорректно.

Сводные таблицы

Общая таблица лучших конфигураций

Группа методов	Набор	Лучшая конфигурация	Основная метрика	Значение
dz2	WikIR	лучший BM25	nDCG@20	0.3892
dz2	MIRAGE	лучший BM25	nDCG@20	0.4555
dz3	WikIR	лучший обученный ранжировщик	nDCG@20	0.4773
dz4	WikIR	лучший смысловой поиск, all-MiniLM-L6-v2	nDCG@20	0.4705
dz4	MIRAGE	лучший смысловой поиск, all-MiniLM-L6-v2	nDCG@20	0.7694
dz4	WikIR	лучшее переупорядочивание, k = 100	nDCG@20	0.3910
dz4	MIRAGE	лучшее переупорядочивание, k = 100	nDCG@20	0.6145
dz4	WikIR	смешанная модель, alpha = 0.1	nDCG@20	0.4900
dz4	MIRAGE	смешанная модель, alpha = 0.1	nDCG@20	0.7820

В этой таблице оставлены только строки, где основная метрика сопоставима напрямую.

WikIR: сопоставление лучших конфигураций по nDCG@20

Подход	Лучшая конфигурация	nDCG@20	Комментарий
dz2	лучший BM25	0.3892	сильная лексическая база
dz3	лучший обученный ранжировщик	0.4773	прямое сравнение возможно
dz4	all-MiniLM-L6-v2	0.4705	лучший чистый смысловой поиск
dz4	paraphrase-multilingual-MiniLM-L12-v2	0.2757	заметно слабее
dz4	лучшее переупорядочивание, k = 100	0.3910	хуже чистого смыслового поиска
dz4	смешанная модель, alpha = 0.1	0.4900	лучший итоговый результат

MIRAGE: сопоставимые результаты по nDCG@20

Подход	Лучшая конфигурация	nDCG@20	Комментарий
dz2	лучший BM25	0.4555	базовый лексический поиск

Подход	Лучшая конфигурация	nDCG@20	Комментарий
dz4	all-MiniLM-L6-v2	0.7694	лучший чистый смысловой поиск
dz4	paraphrase-multilingual-MiniLM-L12-v2	0.6469	слабее
dz4	лучшее переупорядочивание, k = 100	0.6145	all-MiniLM-L6-v2 хуже чистого смыслового поиска
dz4	смешанная модель, alpha = 0.1	0.7820	лучший сопоставимый результат

MIRAGE: справочно о лучшем результате из dz3

Подход	Лучшая конфигурация	Метрики	Комментарий
dz3	лучший обученный ранжировщик	AP = 0.7356, nDCG@5 = 0.8055	полезно для ориентира, но не для прямого численного сравнения с nDCG@20

Графики

WikiR: сравнение лучших конфигураций по nDCG@20




Figure 2: WikiR: сравнение по nDCG@20

MIRAGE: сравнение сопоставимых конфигураций по nDCG@20

Примечание: лучший результат из dz3 для MIRAGE не включён в этот график, потому что там сохранены AP и nDCG@5, а не nDCG@20.




Figure 3: MIRAGE: сравнение по nDCG@20

Интерпретация результатов

- Самая цельная картина здесь такая: сочетание лексического сигнала BM25 и смыслового сходства работает лучше, чем каждый из этих сигналов по отдельности.
- Лучшая из двух выбранных моделей для смыслового поиска: all-MiniLM-L6-v2.
- Сама по себе более крупная многоязычная модель paraphrase-multilingual-MiniLM-L12-v2 в этом задании оказалась слабее на обоих наборах.
- Переупорядочивание в текущем виде оказалось самым слабым местом работы. Оно не улучшает, а ухудшает результат относительно лучшего нейросетевого поиска.
- Смешанная модель, напротив, выглядит логично и устойчиво: небольшой вклад BM25 дополняет смысловой поиск и даёт лучший итог.

Ограничения эксперимента

- Переупорядочивание построено на косинусной близости той же модели, а не на отдельной парной модели. Это ограничивает потенциал улучшения.
- Для MIRAGE из dz3 сохранены другие метрики, поэтому прямое сравнение по nDCG@20 недоступно.
- В отчёте не рассматривается дополнительное задание с дообучением парной модели, потому что базовая часть работы уже позволяет сделать содержательные выводы.

Что можно улучшить

- Для этапа переупорядочивания стоит попробовать отдельную парную модель. Именно здесь сейчас главный резерв качества.
- Для более строгого сравнения с dz3 на MIRAGE стоит пересчитать старые результаты в тех же метриках, что используются в dz4.
- Дополнительное задание с дообучением парной модели остаётся самым естественным направлением усиления работы.

Воспроизводимость

- Основной сценарий реализован в `run_dz4_experiments.py`.
- Итоговые сводки лежат в `summary.json`, `summary.md` и `report.md`.
- Таблицы результатов лежат в каталоге `dz4/artifacts/tables`.
- Файлы ранжирования в формате TREC лежат в каталоге `dz4/artifacts/runs`.
- Кэш представлений лежит в каталоге `dz4/artifacts/cache`.
- Для полного повторения достаточно запустить:

```
python3 '/Users/georgijmamarin/Desktop/Oplimp/AITH Search/dz4/scripts/run_dz4_experiments.py'
```

Вывод

- Среди двух моделей лучшей оказалась `all-MiniLM-L6-v2`.
- Лучший итоговый результат даёт смешанная модель с `alpha = 0.1`.
- Чистый смысловой поиск уже сильнее классического BM25, а наилучший результат достигается при аккуратном объединении обоих сигналов.