

Contents

HA5: ответы на вопросы на MIRAGE

Краткий итог

1. Постановка и данные

2. Модели и настройки

3. Метрики

4. Таблица результатов

5. Графики

6. Анализ

7. Покрытие пунктов задания

8. Ограничения и воспроизводимость

9. Артефакты

1

1

1

2

2

4

9

9

10

10

HA5: ответы на вопросы на MIRAGE

Краткий итог

Все пункты задания закрыты на одной фиксированной выборке из 1000 вопросов MIRAGE. Лучшее качество дает oracle-контекст: RoBERTa oracle достигает 0.632 SQuAD EM и 0.752 SQuAD F1, а Qwen oracle дает 0.735 SQuAD F1 и максимальную долю верных или частично верных ответов по LLM-судье - 0.891.

Среди режимов без oracle-контекста сильнее всего оказался Qwen с готовым смешанным контекстом MIRAGE: 0.692 SQuAD F1 и 0.687 MIRAGE loose. Top-5 контекст от ранжировщиков HA4 заметно лучше top-1, что показывает важность полноты поиска для итогового QA-качества.

Дообученная T5Gemma 270M в текущем LoRA-сценарии дала отрицательный результат: строковые метрики и BERTScore почти нулевые, LLM-судья считает только около 24% ответов частично полезными, а строго верных ответов почти нет.

1. Постановка и данные

В работе сравниваются несколько режимов ответа на вопросы на наборе данных MIRAGE. Чтобы вычисления были воспроизводимыми и сопоставимыми с HA4, используется фиксированная случайная выборка из 1000 вопросов. Выборка построена из тестовой части MIRAGE, для которой уже были рассчитаны ранжировщики HA4; список query_id сохранен в отдельной папке artifacts/data/mirage_sample_1000_qids.txt.

Одна и та же выборка используется во всех экспериментах:

- генерация без контекста;
- генерация с oracle-контекстом;
- экстрактивная QA-модель с oracle-пассажем;
- top-1 контексты от двух ранжировщиков HA4;
- top-5 контексты от двух ранжировщиков HA4;
- смешанный контекст MIRAGE;
- дообученная T5Gemma в режимах без контекста, oracle, top-1 mixture и top-1 dense;
- оценка LLM-судьей для всех полных предсказаний.

Два ранжировщика из HA4:

- ha4_mixture: лучший mixture-прогон из HA4;

- ha4_dense: dense-прогон MiniLM как независимый сильный базовый вариант.

2. Модели и настройки

Генеративная SLM:

- Qwen/Qwen2.5-1.5B-Instruct;
- детерминированная генерация;
- max_new_tokens=16;
- ограничение контекста: 6000 символов.

Экстрактивная QA:

- deepset/roberta-base-squad2;
- max_seq_len=384;
- doc_stride=128.

Дообученная SLM:

- базовая модель google/t5gemma-2-270m-270m;
- LoRA-адаптация на SQuAD;
- 87599 обучающих примеров и 256 примеров для валидации;
- 1 эпоха, размер пакета 1, накопление градиента на 16 шагах;
- оценка на тех же 1000 вопросах MIRAGE в четырех режимах.

Оценка LLM-судьей:

- Qwen/Qwen2.5-1.5B-Instruct;
- инструкция с выбором одной из четырех меток: correct, partially_correct, incorrect, unanswerable_or_bad_context.
- всего 14000 оценок: 10 основных прогонов и 4 T5Gemma-прогона по 1000 ответов.

3. Метрики

Автоматические метрики:

- точное совпадение в стиле SQuAD;
- токеновый F1 в стиле SQuAD;
- строгое точное совпадение MIRAGE;
- мягкое точное совпадение MIRAGE;
- BERTScore F1 с моделью bert-base-uncased.

Метрики MIRAGE воспроизводят формулы из официального LLM_Evaluator репозитория nlpai-lab/MIRAGE: строки приводятся к нижнему регистру, strict требует полного совпадения ответа и предсказания, loose засчитывает ответ, если один из допустимых ответов входит в предсказание.


LLM-судья используется как дополнительная качественная оценка.

4. Таблица результатов


Опыт	Вид	Контекст	N	SQuAD EM	SQuAD F1	MIRAGE loose	BERTScore F1	LLM: верно	LLM: верно/частично
RoBERTa oracle	извлечение	oracle	1000	0.632	0.752	0.748	0.847	0.479	0.854
RoBERTa top-1 mixture	извлечение	top-1 mixture	1000	0.376	0.469	0.450	0.692	0.299	0.623
RoBERTa top-1 dense	извлечение	top-1 dense	1000	0.372	0.461	0.441	0.687	0.302	0.616
Qwen без контекста	генерация	без контекста	1000	0.016	0.060	0.026	0.449	0.086	0.272
Qwen oracle	генерация	oracle	1000	0.578	0.735	0.734	0.819	0.522	0.891
Qwen top-1 mixture	генерация	top-1 mixture	1000	0.345	0.457	0.429	0.661	0.344	0.624
Qwen top-1 dense	генерация	top-1 dense	1000	0.333	0.448	0.423	0.657	0.343	0.615
Qwen top-5 mixture	генерация	top-5 mixture	1000	0.431	0.558	0.553	0.724	0.393	0.748
Qwen top-5 dense	генерация	top-5 dense	1000	0.447	0.577	0.571	0.736	0.409	0.754
Qwen MIRAGE mixed	генерация	MIRAGE mixed	1000	0.545	0.692	0.687	0.796	0.480	0.863
T5Gemma без контекста	дообучение	без контекста	1000	0.000	0.001	0.001	0.012	0.002	0.242
T5Gemma oracle	дообучение	oracle	1000	0.000	0.000	0.000	0.000	0.001	0.239
T5Gemma top-1 mixture	дообучение	top-1 mixture	1000	0.000	0.000	0.000	0.000	0.001	0.239
T5Gemma top-1 dense	дообучение	top-1 dense	1000	0.000	0.000	0.000	0.000	0.001	0.239

Полная CSV-таблица: artifacts/tables/dz5_full_results_for_report.csv.


5. Графики




MIRAGE loose EM на полной выборке




BERTScore F1 на полной выборке



LLM-судья: верно или частично верно



T5Gemma: доля пустых ответов



6. Анализ

Без контекста модель отвечает плохо: Qwen получает только 0.060 SQuAD F1 и 0.026 MIRAGE loose. Это подтверждает, что MIRAGE в нашей выборке требует внешнего контекста, а не только параметрических знаний модели.

Oracle-контекст дает максимальный прирост качества. Qwen oracle поднимается до 0.735 SQuAD F1, а RoBERTa oracle дает лучшее точное совпадение: 0.632 SQuAD EM. Это ожидаемо: oracle-пассажи содержат ответ, а экстрактивная модель хорошо извлекает короткий фрагмент ответа.

Топ-1 контекст от ранжировщиков заметно лучше режима без контекста, но сильно уступает oracle. Для Qwen top-1 mixture и top-1 dense дают 0.457 и 0.448 SQuAD F1. Для RoBERTa top-1 mixture и dense дают 0.469 и 0.461. Это показывает, что основной источник ошибки в top-1 режиме - промах поиска: если первый пассаж не содержит ответа, QA-модель не может восстановить правильный ответ.

Топ-5 контекст улучшает генеративную QA относительно top-1. Qwen top-5 dense достигает 0.577 SQuAD F1, top-5 mixture - 0.558. Dense немного сильнее mixture в QA-режиме, хотя HA4 mixture был сильным ранжировщиком. Возможное объяснение: top-5 dense чаще дает полезный набор фактов для генерации, тогда как mixture лучше оптимизирован под метрики поиска, но не обязательно под итоговую QA-задачу.

Смешанный контекст MIRAGE остается сильнейшим генеративным режимом без oracle-контекста: 0.692 SQuAD F1 и 0.687 MIRAGE loose. Это логично, потому что смешанный контекст в MIRAGE является более курированным источником контекста, чем сырые top-k документы ранжировщика.

Дообученная T5Gemma в текущем LoRA-сценарии не дала полезного QA-качества на MIRAGE: все четыре режима имеют около нуля по SQuAD EM/F1 и MIRAGE loose. Причина видна и в самих предсказаниях: в режиме без контекста пустыми оказались 968 из 1000 ответов, а в oracle, top-1 mixture и top-1 dense - все 1000 из 1000. Поэтому это не пограничный случай строковых метрик, а фактический срыв генерации ответов в выбранном формате. Это важный отрицательный результат: одной эпохи SQuAD-дообучения с компактной T5Gemma 270M и текущим форматом генерации недостаточно, чтобы конкурировать с инструкционной моделью Qwen или экстрактивной RoBERTa.

Оценка LLM-судьей согласуется с общей картиной, но дает более мягкий результат. Например, Qwen oracle имеет 0.891 по доле верных или частично верных ответов против 0.734 MIRAGE loose. Для T5Gemma судья тоже мягче строковых метрик: около 0.239-0.242 ответов помечены как верные или частично верные, но доля строго верных ответов остается около 0.001-0.002. Это значит, что LLM-судья иногда засчитывает слабые или частично полезные формулировки, которые EM/F1 штрафуют. Поэтому такая оценка полезна как дополнительный анализ, но не заменяет EM/F1.

BERTScore также сохраняет общий порядок систем: максимум у RoBERTa oracle (0.847), затем Qwen oracle (0.819) и Qwen MIRAGE mixed (0.796). Для T5Gemma BERTScore близок к нулю: 0.012 в режиме без контекста и 0.000 в остальных трех режимах, что согласуется с большим числом пустых или нерелевантных ответов. Обычно абсолютные значения BERTScore выше строковых метрик, потому что он измеряет близость контекстных представлений, а не точное совпадение строк; здесь он дополнительно подтверждает провал текущего T5Gemma-сценария.

7. Покрытие пунктов задания

Пункт	Комментарий
SLM без контекста, 0-shot	Qwen2.5-1.5B-Instruct, 1000 вопросов
Экстрактивная QA / MRC	RoBERTa SQuAD2, oracle/top-1, 1000 вопросов
SLM с oracle-контекстом	Qwen + oracle-контекст
Топ-1 контекст из ранжировщиков HA4	mixture/dense для Qwen и RoBERTa
Топ-5 контекст из ранжировщиков HA4	mixture/dense для Qwen
Смешанный контекст	MIRAGE Qwen MIRAGE mixed
Оценка LLM-судьей	14000 оценок, включая 4000 ответов T5Gemma
Дообучение T5Gemma	LoRA-дообучение на SQuAD и оценка 4 режимов на 1000 вопросах
BERTScore	посчитан для всех 14 полных прогонов с bert-base-uncased

8. Ограничения и воспроизводимость

Дообучение google/t5gemma-2-270m-270m выполнено как LoRA-адаптация на SQuAD с последующей оценкой на 1000 вопросах MIRAGE в режимах без контекста, oracle, top-1 mixture и top-1 dense. Для T5Gemma использовалось отдельное локальное GPU-окружение, так как архитектура требует свежей dev-версии transformers. Метрики и BERTScore считались в основном окружении со стабильной версией transformers и пакетом bert-score. LLM-судья для T5Gemma также досчитан отдельно и включен в итоговую сводку.

Главное содержательное ограничение эксперимента - фиксированная выборка из 1000 вопросов. Она позволяет сделать все методы сравнимыми между собой при ограниченных вычислительных ресурсах, но не заменяет полный прогон по всему MIRAGE.

9. Артефакты

- Данные: artifacts/data/mirage_eval_sample_1000.jsonl
- Предсказания: artifacts/predictions/*.jsonl
- Метрики: artifacts/metrics/*_metrics.json
- Таблица результатов: artifacts/tables/dz5_full_results_for_report.csv
- Сводка покрытия: artifacts/tables/dz5_task_coverage.md
- Оценка LLM-судьей: artifacts/judge/llm_judge_qwen2_5_1_5b_v2.jsonl