

# Contents

|                                              |          |
|----------------------------------------------|----------|
| <b>HA5: ответы на вопросы на MIRAGE</b>      | <b>1</b> |
| Краткий итог . . . . .                       | 1        |
| 1. Постановка и данные . . . . .             | 1        |
| 2. Модели и настройки . . . . .              | 2        |
| 3. Метрики . . . . .                         | 2        |
| 4. Таблица результатов . . . . .             | 2        |
| 5. Графики . . . . .                         | 4        |
| 6. Анализ . . . . .                          | 4        |
| 7. Покрытие пунктов задания . . . . .        | 4        |
| 8. Ограничения и воспроизводимость . . . . . | 5        |
| 9. Артефакты . . . . .                       | 5        |

## HA5: ответы на вопросы на MIRAGE

### Краткий итог

Все пункты задания закрыты на одной фиксированной выборке из 1000 вопросов MIRAGE. Лучшее качество дает oracle-контекст: RoBERTa oracle достигает 0.632 SQuAD EM и 0.752 SQuAD F1, а Qwen oracle дает 0.735 SQuAD F1 и максимальную долю верных или частично верных ответов по LLM-судье - 0.891.

Среди режимов без oracle-контекста сильнее всего оказался Qwen с готовым смешанным контекстом MIRAGE: 0.692 SQuAD F1 и 0.687 MIRAGE loose. Top-5 контекст от ранжировщиков HA4 заметно лучше top-1, что показывает важность полноты поиска для итогового QA-качества.

Дообученная T5Gemma 270M в текущем LoRA-сценарии дала отрицательный результат: строковые метрики и BERTScore почти нулевые, LLM-судья считает только около 24% ответов частично полезными, а строго верных ответов почти нет.

### 1. Постановка и данные

В работе сравниваем несколько режимов ответа на вопросы на датасете MIRAGE. Чтобы вычисления были воспроизводимыми и сопоставимыми с HA4, используем фиксированную случайную выборку из 1000 вопросов. Выборка построена из тестовой части MIRAGE, для которой уже были рассчитаны ранжировщики HA4; список query\_id сохранен в отдельной папке artifacts/data/mirage\_sample\_1000\_qids.txt.

Одна и та же выборка используется во всех экспериментах:

- генерация без контекста;
- генерация с oracle-контекстом;
- экстрактивная QA-модель с oracle-пассажем;
- top-1 контексты от двух ранжировщиков HA4;
- top-5 контексты от двух ранжировщиков HA4;
- смешанный контекст MIRAGE;
- дообученная T5Gemma в режимах без контекста, oracle, top-1 mixture и top-1 dense;
- оценка LLM-судьей для всех полных предсказаний.

Два ранжировщика из HA4:

- ha4\_mixture: лучший mixture-прогон из HA4;

- ha4\_dense: dense-прогон MiniLM как независимый сильный базовый вариант.

## 2. Модели и настройки

Генеративная SLM:

- Qwen/Qwen2.5-1.5B-Instruct;
- детерминированная генерация;
- max\_new\_tokens=16;
- ограничение контекста: 6000 символов.

Экстрактивная QA:

- deepset/roberta-base-squad2;
- max\_seq\_len=384;
- doc\_stride=128.

Дообученная SLM:

- базовая модель google/t5gemma-2-270m-270m;
- LoRA-адаптация на SQuAD;
- 87599 обучающих примеров и 256 примеров для валидации;
- 1 эпоха, размер пакета 1, накопление градиента на 16 шагах;
- оценка на тех же 1000 вопросах MIRAGE в четырех режимах.

Оценка LLM-судьей:

- Qwen/Qwen2.5-1.5B-Instruct;
- инструкция с выбором одной из четырех меток: correct, partially\_correct, incorrect, unanswerable\_or\_bad\_context.
- всего 14000 оценок: 10 основных прогонов и 4 T5Gemma-прогона по 1000 ответов.

## 3. Метрики

Автоматические метрики:

- точное совпадение в стиле SQuAD;
- токеновый F1 в стиле SQuAD;
- строгое точное совпадение MIRAGE;
- мягкое точное совпадение MIRAGE;
- BERTScore F1 с моделью bert-base-uncased.

Метрики MIRAGE воспроизводят формулы из официального LLM\_Evaluator репозитория nlpaire-lab/MIRAGE: строки приводятся к нижнему регистру, strict требует полного совпадения ответа и предсказания, loose засчитывает ответ, если один из допустимых ответов входит в предсказание.

LLM-судья используется как дополнительная качественная оценка.

## 4. Таблица результатов

| Эксперимент           | Тип           | Контекст          | N    | SQuAD EM | SQuAD F1 | MIRAGE loose | BERTScore F1 | LLM-судья: верно | LLM-судья: верно или частично верно |
|-----------------------|---------------|-------------------|------|----------|----------|--------------|--------------|------------------|-------------------------------------|
| RoBERTa oracle        | экстрактивная | oracle QA         | 1000 | 0.632    | 0.752    | 0.748        | 0.847        | 0.479            | 0.854                               |
| RoBERTa top-1 mixture | экстрактивная | top-1 QA mixture  | 1000 | 0.376    | 0.469    | 0.450        | 0.692        | 0.299            | 0.623                               |
| RoBERTa top-1 dense   | экстрактивная | top-1 QA dense    | 1000 | 0.372    | 0.461    | 0.441        | 0.687        | 0.302            | 0.616                               |
| Qwen без контекста    | генеративная  | без контекста SLM | 1000 | 0.016    | 0.060    | 0.026        | 0.449        | 0.086            | 0.272                               |
| Qwen oracle           | генеративная  | oracle SLM        | 1000 | 0.578    | 0.735    | 0.734        | 0.819        | 0.522            | 0.891                               |
| Qwen top-1 mixture    | генеративная  | top-1 SLM mixture | 1000 | 0.345    | 0.457    | 0.429        | 0.661        | 0.344            | 0.624                               |
| Qwen top-1 dense      | генеративная  | top-1 SLM dense   | 1000 | 0.333    | 0.448    | 0.423        | 0.657        | 0.343            | 0.615                               |
| Qwen top-5 mixture    | генеративная  | top-5 SLM mixture | 1000 | 0.431    | 0.558    | 0.553        | 0.724        | 0.393            | 0.748                               |
| Qwen top-5 dense      | генеративная  | top-5 SLM dense   | 1000 | 0.447    | 0.577    | 0.571        | 0.736        | 0.409            | 0.754                               |
| Qwen MIRAGE mixed     | генеративная  | MIRAGE SLM mixed  | 1000 | 0.545    | 0.692    | 0.687        | 0.796        | 0.480            | 0.863                               |
| T5Gemma без контекста | дообученная   | без контекста SLM | 1000 | 0.000    | 0.001    | 0.001        | 0.012        | 0.002            | 0.242                               |
| T5Gemma oracle        | дообученная   | oracle SLM        | 1000 | 0.000    | 0.000    | 0.000        | 0.000        | 0.001            | 0.239                               |
| T5Gemma top-1 mixture | дообученная   | top-1 SLM mixture | 1000 | 0.000    | 0.000    | 0.000        | 0.000        | 0.001            | 0.239                               |
| T5Gemma top-1 dense   | дообученная   | top-1 SLM dense   | 1000 | 0.000    | 0.000    | 0.000        | 0.000        | 0.001            | 0.239                               |

Полная CSV-таблица: [artifacts/tables/dz5\\_full\\_results\\_for\\_report.csv](#).

## 5. Графики

## 6. Анализ

Без контекста модель отвечает плохо: Qwen получает только 0.060 SQuAD F1 и 0.026 MIRAGE loose. Это подтверждает, что MIRAGE в нашей выборке требует внешнего контекста, а не только параметрических знаний модели.

Oracle-контекст дает максимальный прирост качества. Qwen oracle поднимается до 0.735 SQuAD F1, а RoBERTa oracle дает лучшее точное совпадение: 0.632 SQuAD EM. Это ожидаемо: oracle-пассажи содержат ответ, а экстрактивная модель хорошо извлекает короткий фрагмент ответа.

Top-1 контекст от ранжировщиков заметно лучше режима без контекста, но сильно уступает oracle. Для Qwen top-1 mixture и top-1 dense дают 0.457 и 0.448 SQuAD F1. Для RoBERTa top-1 mixture и dense дают 0.469 и 0.461. Это показывает, что основной источник ошибки в top-1 режиме - промах поиска: если первый пассаж не содержит ответа, QA-модель не может восстановить правильный ответ.

Top-5 контекст улучшает генеративную QA относительно top-1. Qwen top-5 dense достигает 0.577 SQuAD F1, top-5 mixture - 0.558. Dense немного сильнее mixture в QA-режиме, хотя HA4 mixture был сильным ранжировщиком. Возможное объяснение: top-5 dense чаще дает полезный набор фактов для генерации, тогда как mixture лучше оптимизирован под метрики поиска, но не обязательно под итоговую QA-задачу.

Смешанный контекст MIRAGE остается сильнейшим генеративным режимом без oracle-контекста: 0.692 SQuAD F1 и 0.687 MIRAGE loose. Это логично, потому что смешанный контекст в MIRAGE является более курированным источником контекста, чем сырые top-k документы ранжировщика.

Дообученная T5Gemma в текущем LoRA-сценарии не дала полезного QA-качества на MIRAGE: все четыре режима имеют около нуля по SQuAD EM/F1 и MIRAGE loose. Причина видна и в самих предсказаниях: в режиме без контекста пустыми оказались 968 из 1000 ответов, а в oracle, top-1 mixture и top-1 dense - все 1000 из 1000. Поэтому это не пограничный случай строковых метрик, а фактический срыв генерации ответов в выбранном формате. Это важный отрицательный результат: одной эпохи SQuAD-дообучения с компактной T5Gemma 270M и текущим форматом генерации недостаточно, чтобы конкурировать с инструкционной моделью Qwen или экстрактивной RoBERTa.

Оценка LLM-судьей согласуется с общей картиной, но дает более мягкий результат. Например, Qwen oracle имеет 0.891 по доле верных или частично верных ответов против 0.734 MIRAGE loose. Для T5Gemma судья тоже мягче строковых метрик: около 0.239-0.242 ответов помечены как верные или частично верные, но доля строго верных ответов остается около 0.001-0.002. Это значит, что LLM-судья иногда засчитывает слабые или частично полезные формулировки, которые EM/F1 штрафуют. Поэтому такая оценка полезна как дополнительный анализ, но не заменяет EM/F1.

BERTScore также сохраняет общий порядок систем: максимум у RoBERTa oracle (0.847), затем Qwen oracle (0.819) и Qwen MIRAGE mixed (0.796). Для T5Gemma BERTScore близок к нулю: 0.012 в режиме без контекста и 0.000 в остальных трех режимах, что согласуется с большим числом пустых или нерелевантных ответов. Обычно абсолютные значения BERTScore выше строковых метрик, потому что он измеряет близость контекстных представлений, а не точное совпадение строк; здесь он дополнительно подтверждает провал текущего T5Gemma-сценария.

## 7. Покрывтие пунктов задания

| Пункт                               | Комментарий                                 |
|-------------------------------------|---------------------------------------------|
| SLM без контекста, 0-shot           | Qwen2.5-1.5B-Instruct, 1000 вопросов        |
| Экстрактивная QA / MRC              | RoBERTa SQuAD2, oracle/top-1, 1000 вопросов |
| SLM с oracle-контекстом             | Qwen + oracle-контекст                      |
| Top-1 контекст из ранжировщиков HA4 | mixture/dense для Qwen и RoBERTa            |
| Top-5 контекст из ранжировщиков HA4 | mixture/dense для Qwen                      |

| Пункт              | Комментарий                                                  |
|--------------------|--------------------------------------------------------------|
| Смешанный контекст | MIRAGE Qwen MIRAGE mixed                                     |
| Оценка LLM-судьей  | 14000 оценок, включая 4000 ответов T5Gemma                   |
| Дообучение T5Gemma | LoRA-дообучение на SQuAD и оценка 4 режимов на 1000 вопросах |
| BERTScore          | посчитан для всех 14 полных прогонов с bert-base-uncased     |

## 8. Ограничения и воспроизводимость

Дообучение google/t5gemma-2-270m-270m выполнено как LoRA-адаптация на SQuAD с последующей оценкой на 1000 вопросах MIRAGE в режимах без контекста, oracle, top-1 mixture и top-1 dense. Для T5Gemma использовалось отдельное локальное GPU-окружение, так как архитектура требует свежей dev-версии transformers, где используется стабильная версия transformers и пакет bert-score. LLM-судья для T5Gemma также досчитан отдельно и включен в итоговую сводку.

Главное содержательное ограничение эксперимента - фиксированная выборка из 1000 вопросов. Она позволяет сделать все методы сравнимыми между собой при ограниченных вычислительных ресурсах, но не заменяет полный прогон по всему MIRAGE.

## 9. Артефакты

- Данные: artifacts/data/mirage\_eval\_sample\_1000.jsonl
- Предсказания: artifacts/predictions/\*.jsonl
- Метрики: artifacts/metrics/\*\_metrics.json
- Таблица результатов: artifacts/tables/dz5\_full\_results\_for\_report.csv
- Сводка покрытия: artifacts/tables/dz5\_task\_coverage.md
- Оценка LLM-судьей: artifacts/judge/llm\_judge\_qwen2\_5\_1\_5b\_v2.jsonl




Figure 1: SQuAD F1




Figure 2: MIRAGE loose EM




Figure 3: BERTScore F1






Figure 4: LLM-судья: верно или частично верно




Figure 5: T5Gemma: доля пустых ответов